

Escriba

Le traducteur universel vers le langage de l'IA

Manuel complet — utilisateurs et administrateurs

Développé par Diego Parrás · CeMIACE · SEUBES · FCE-UBA

github.com/diegoparras/escriba

Partie 1 — Pour les utilisateurs

Qu'est-ce qu'Escriba ?

Escriba convertit presque n'importe quel fichier en Markdown propre — du texte mis en forme, prêt à copier, enregistrer ou transmettre à une IA. Il gère documents, tableurs, présentations, images, audio, vidéo et YouTube.

Premiers pas

- Saisissez le mot de passe et connectez-vous (votre niveau : HUMANO, ANGEL ou DIOS).
- Glissez des fichiers sur la zone centrale, ou cliquez sur « Sélectionner des fichiers ».
- Cliquez sur « Tout convertir ». Une barre de progression apparaît.
- Ouvrez le résultat et utilisez Aperçu / Markdown / Divisé. Copiez-le ou téléchargez le .md (ou un .zip pour plusieurs fichiers).

Fonctionnalités clés

- L'audio et la vidéo sont transcrits en local avec Whisper ; choisissez la langue dans les options avancées.
- Collez un lien YouTube pour obtenir sa transcription.
- Le texte des images est traité par OCR automatiquement ; les PDF scannés sont détectés, traités et redressés à la volée.
- L'IA est optionnelle (OpenAI, Gemini, OpenRouter) et par défaut sur « Sans IA ». Les modèles sont listés automatiquement.
- Anonymisation des PII pour LLM : moteur local (NER + structure des factures + détecteurs validés + vos règles) avec cinq modes de sortie — typé, anonyme, pseudonymisation réversible (jeton → au LLM → ré-hydratation), masquage partiel (••••-3456) et hash stable (même donnée → même pseudonyme entre documents).
- Caviardage visuel : téléchargez votre PDF ou image scannée avec les PII noircies sur la page — caviardage réel : le texte et les pixels en dessous sont supprimés du fichier. Les métadonnées du document (titre, auteur, mots-clés) sont également effacées, pour que rien ne fuite via les Propriétés du fichier.
- File d'attente : convertissez tout ou seulement les fichiers sélectionnés.
- Thème clair/sombre et interface disponible en 7 langues.
- Export au-delà du Markdown : un menu unifié convertit le résultat en Word (.docx), ODT, EPUB, HTML, LaTeX, reStructuredText ou XML structuré (DocBook, JATS, TEI, OPML), via Pandoc — sans IA.
- Panneau de préparation LLM à chaque conversion : nombre de jetons, jetons et coût économisés par l'anonymisation, une estimation de coût en direct par modèle (tarifs OpenRouter), adéquation à la fenêtre de contexte, découpage RAG en un clic et un détecteur d'injection de prompt — le tout en local.
- Extraction PDF avancée (optionnelle) : le moteur OpenDataLoader reconstruit les mises en page complexes avec un meilleur ordre de lecture et une hiérarchie des titres, en revenant automatiquement à l'extracteur par défaut.
- Sélection de pages (PDF) : convertissez uniquement les pages dont vous avez besoin — une plage (5-67), des pages individuelles (1, 6, 9) ou un mélange (1, 2, 5-67), choisissez fichier par fichier avec un sélecteur simple qui affiche le nombre de pages.

Partie 2 — Rôles et niveaux d'accès

La connexion est requise. Chaque niveau a son propre mot de passe et ses limites, tous configurables par variables d'environnement.

Capacité	HUMANO	ANGEL	DIOS
Envoyer et convertir des fichiers	Oui	Oui	Oui
Convertir depuis une URL publique	Non	Oui	Oui
URL interne / chemin local	Non	Non	Oui
Audio / vidéo / ZIP	Non	Oui	Oui
Transcriptions YouTube	Oui	Oui	Oui
OCR (forcé / automatique)	Non	Oui	Oui
Utiliser les clés IA du serveur	Non	Oui	Oui
Taille max de fichier	25 Mo	100 Mo	illimité
Fichiers par lot	3	10	illimité
Limite de débit (req/min)	15	60	illimité

Partie 3 — Pour les administrateurs

Architecture

Escriba s'exécute dans un unique conteneur Docker autonome qui embarque FastAPI + Markdown, ffmpeg, Tesseract + OCRmyPDF, faster-whisper et un Redis intégré. Il tourne en utilisateur non-root, avec healthcheck et détection automatique des cœurs.

Déploiement

Lancez l'image préconstruite (sans build) :

```
docker run -d --name escriba -p 8000:8000 \
  -e SECRET_KEY="<long-random-key>" \
  -e GOD_PASSWORD="<your-password>" \
  ghcr.io/diegoparras/escriba:latest
```

Ou avec Docker Compose :

```
git clone https://github.com/diegoparras/escriba.git
cd escriba
cp .env.example .env
docker compose up -d --build
```

EasyPanel/Portainer/Dokploy : créez une App à partir de l'image Docker

ghcr.io/diegoparras/escriba:latest, ajoutez les variables d'environnement, dirigez le domaine vers le port 8000 du conteneur avec HTTPS, puis déployez.

Variables d'environnement

Variable	Défaut	Description
SECRET_KEY	aléatoire	Clé de signature des sessions. À définir en production.
GOD/ANGEL/HUMAN_PASSWORD	—	Mot de passe de chaque niveau d'accès.
HUMAN_OPEN	false	Autorise le niveau HUMANO sans connexion.
WEB_CONCURRENCY	auto	Workers parallèles (auto = cœurs CPU).
MAX_UPLOAD_MB	100	Taille max d'envoi (sauf DIOS).
WHISPER_MODEL	base	Modèle de transcription (tiny ... large-v3).
MAX_MEDIA_MINUTES	120	Durée max audio/vidéo (0 = illimité).
OPENAI/OPENROUTER/GOOGLE_API_KEY	—	Clés IA côté serveur (repli).
API_TOKEN / API_TOKEN_ROLE	— / angel	Jeton pour l'automatisation et son rôle.
EMBEDDED_REDIS	true	Redis intégré pour la limitation partagée.
ENABLE_DOCS	false	Exposer Swagger sur /api/docs.

Clés IA côté serveur

- Si définies, les utilisateurs n'ont pas besoin de coller la leur. Seuls DIOS et ANGEL les utilisent.
- Le coût est pour vous et partagé. Laissez-les vides pour que chacun apporte la sienne.
- Une clé fournie par l'utilisateur a toujours priorité sur celle du serveur.

Transcription (Whisper)

- Définissez le modèle avec WHISPER_MODEL (plus grand = plus précis, plus lent).
- Il tourne sur CPU. MAX_MEDIA_MINUTES plafonne la durée (DIOS sans limite).

Jeton d'API (automatisation)

Pour n8n ou des scripts, définissez API_TOKEN et envoyez-le en en-tête :

```
curl -H "X-API-Key: YOUR_TOKEN" \  
  -F "file=@document.pdf" \  
  https://your-domain/api/convert
```

Sécurité

- Authentification requise ; trois rôles aux permissions distinctes.
- Anti-SSRF (IP internes/redirections bloquées) ; chemins locaux réservés à DIOS.
- Nettoyage XSS (DOMPurify) et en-têtes de sécurité (CSP).
- Conteneur non-root avec no-new-privileges ; OCR/Whisper sans shell.
- Limitation de débit par rôle ; la clé API n'est jamais stockée sur le serveur.

Confidentialité

Les fichiers envoyés sont traités dans un fichier temporaire et supprimés dès la fin de la conversion (succès ou erreur). Aucune base de données ni dossier d'envois ; le résultat n'est transmis qu'à votre navigateur.

Partie 4 — Référence de l'API

Endpoint	Méthode	Description
/api/login	POST	Connexion ; définit un cookie de session.
/api/me	GET	Rôle actuel et capacités.
/api/convert	POST	Convertit un fichier ou une URL en Markdown.
/api/models	POST	Liste les modèles du fournisseur.
/api/stats	GET	Statistiques serveur (par rôle).
/api/export	POST	Convertit le Markdown en docx, odt, epub, html, latex, rst ou XML (DocBook/JATS/TEI/OPML).
/api/compact	POST	Markdown sans espaces superflus pour économiser des jetons.
/api/chunk	POST	Fragments RAG bornés par jetons (.jsonl).
/api/model_prices	GET	Tarifs des modèles et fenêtres de contexte en direct (OpenRouter, en cache).

POST /api/convert (multipart/form-data) : file ou url, plus les options lang, ocr, llm_provider, llm_api_key, llm_model.

Partie 5 — Dépannage

- Une longue vidéo ne se transcrit pas : elle dépasse peut-être MAX_MEDIA_MINUTES — augmentez la limite ou utilisez DIOS.
- Une vidéo YouTube échoue : pas de sous-titres, ou YouTube bloque l'IP du serveur — collez vos cookies YouTube dans les Paramètres, ou définissez YT_PROXY/YT_COOKIES.
- Erreur 413 à l'envoi : augmentez MAX_UPLOAD_MB et la limite de body de votre proxy.
- Un PDF est vide : il était scanné sans OCR pour votre rôle — utilisez ANGEL/DIOS ou cochez « Forcer l'OCR ».
- Mot de passe DIOS oublié : s'il n'est pas défini, un mot de passe aléatoire est affiché dans les logs au démarrage.

Escriba — par Diego Parrás · CeMIACE · SEUBES · FCE-UBA · Licence MIT