

Escriba

Markdown pulito e anonimo per gli LLM

Manuale completo — utenti e amministratori

Sviluppato da Diego Parrás · CeMIACE · SEUBES · FCE-UBA

github.com/diegoparras/escriba

Parte 1 — Per gli utenti

Cos'è Escriba?

Escriba converte quasi qualsiasi file in Markdown pulito — testo formattato, pronto da copiare, salvare o passare a un'IA. Gestisce documenti, fogli di calcolo, presentazioni, immagini, audio, video e YouTube.

Per iniziare

- Inserisci la password e accedi (il tuo livello: HUMANO, ANGEL o DIOS).
- Trascina i file nell'area centrale, o clicca «Seleziona file».
- Clicca «Converti tutto». Appare una barra di avanzamento.
- Apri il risultato e usa Anteprima / Markdown / Diviso. Copialo o scarica il .md (o uno .zip per più file).

Funzioni principali

- Audio e video sono trascritti in locale con Whisper; scegli la lingua nelle opzioni avanzate.
- Incolla un link di YouTube per ottenerne la trascrizione.
- Il testo nelle immagini viene elaborato con OCR automaticamente; i PDF scansionati sono rilevati, elaborati e raddrizzati al volo.
- L'IA è opzionale (OpenAI, Gemini, OpenRouter) e il valore predefinito è «Senza IA». I modelli sono elencati automaticamente.
- Anonimizzazione PII per LLM: motore locale (NER + layout fatture + rilevatori validati + regole proprie) con cinque modalità di output — tipizzata, anonima, pseudonimizzazione reversibile (token → all'LLM → re-idratazione), mascheramento parziale (••••-3456) e hash stabile (stesso dato → stesso pseudonimo tra documenti).
- Censura visiva: scarica il PDF o l'immagine scansionata con i dati oscurati sulla pagina — redazione reale: il testo e i pixel sottostanti vengono rimossi dal file.
- Coda: converti tutto o solo i file selezionati.
- Tema chiaro/scuro e interfaccia disponibile in 7 lingue.

Parte 2 — Ruoli e livelli di accesso

Il login è obbligatorio. Ogni livello ha la propria password e i propri limiti, tutti configurabili tramite variabili d'ambiente.

Capacità	HUMANO	ANGEL	DIOS
Caricare e convertire file	Sì	Sì	Sì
Convertire da URL pubblico	No	Sì	Sì
URL interno / percorso locale	No	No	Sì
Audio / video / ZIP	No	Sì	Sì
Trascrizioni di YouTube	Sì	Sì	Sì
OCR (forzato / automatico)	No	Sì	Sì
Usare le chiavi IA del server	No	Sì	Sì
Dimensione max file	25 MB	100 MB	illimitata
File per lotto	3	10	illimitati
Limite richieste (req/min)	15	60	illimitato

Parte 3 — Per gli amministratori

Architettura

Escriba gira in un unico container Docker autosufficiente che include FastAPI + MarkItDown, ffmpeg, Tesseract + OCRmyPDF, faster-whisper e un Redis integrato. Viene eseguito come utente non-root, con healthcheck e rilevamento automatico dei core.

Distribuzione

Esegui l'immagine già pronta (senza build):

```
docker run -d --name escriba -p 8000:8000 \
  -e SECRET_KEY="<long-random-key>" \
  -e GOD_PASSWORD="<your-password>" \
  ghcr.io/diegoparras/escriba:latest
```

Oppure con Docker Compose:

```
git clone https://github.com/diegoparras/escriba.git
cd escriba
cp .env.example .env
docker compose up -d --build
```

EasyPanel/Portainer/Dokploy: crea un'App dall'immagine Docker ghcr.io/diegoparras/escriba:latest, aggiungi le variabili d'ambiente, punta il dominio alla porta 8000 del container con HTTPS e distribuisci.

Variabili d'ambiente

Variabile	Predefinito	Descrizione
SECRET_KEY	casuale	Chiave di firma delle sessioni. Impostala in produzione.
GOD/ANGEL/HUMAN_PASSWORD	—	Password di ogni livello di accesso.
HUMAN_OPEN	false	Consente il livello HUMANO senza login.
WEB_CONCURRENCY	auto	Worker paralleli (auto = core CPU).
MAX_UPLOAD_MB	100	Dimensione max di caricamento (eccetto DIOS).
WHISPER_MODEL	base	Modello di trascrizione (tiny ... large-v3).
MAX_MEDIA_MINUTES	120	Limite durata audio/video (0 = illimitato).
OPENAI/OPENROUTER/GOOGLE_API_KEY	—	Chiavi IA lato server (ripiego).
API_TOKEN / API_TOKEN_ROLE	— / angel	Token per l'automazione e il suo ruolo.
EMBEDDED_REDIS	true	Redis integrato per il limite condiviso.
ENABLE_DOCS	false	Esporre Swagger su /api/docs.

Chiavi IA lato server

- Se impostate, gli utenti non devono incollare la propria. Solo DIOS e ANGEL le usano.
- Il costo è tuo e condiviso. Lasciale vuote così ognuno usa la propria.
- Una chiave fornita dall'utente ha sempre priorità su quella del server.

Trascrizione (Whisper)

- Imposta il modello con WHISPER_MODEL (più grande = più preciso, più lento).
- Gira su CPU. MAX_MEDIA_MINUTES limita la durata (DIOS senza limite).

Token API (automazione)

Per n8n o script, imposta API_TOKEN e invialo come header:

```
curl -H "X-API-Key: YOUR_TOKEN" \
  -F "file=@document.pdf" \
  https://your-domain/api/convert
```

Sicurezza

- Autenticazione obbligatoria; tre ruoli con permessi distinti.
- Anti-SSRF (IP interni/redirect bloccati); percorsi locali solo per DIOS.
- Sanificazione XSS (DOMPurify) e header di sicurezza (CSP).
- Container non-root con no-new-privileges; OCR/Whisper senza shell.
- Limite richieste per ruolo; la chiave API non viene mai memorizzata sul server.

Privacy

I file caricati vengono elaborati in un file temporaneo ed eliminati appena finisce la conversione (successo o errore). Nessun database né cartella di upload; il risultato viene inviato solo al tuo browser.

Parte 4 — Riferimento API

Endpoint	Metodo	Descrizione
/api/login	POST	Accesso; imposta un cookie di sessione.
/api/me	GET	Ruolo attuale e capacità.
/api/convert	POST	Converte un file o URL in Markdown.
/api/models	POST	Elenca i modelli del provider.
/api/stats	GET	Statistiche server (per ruolo).

POST /api/convert (multipart/form-data): file o url, più gli opzionali lang, ocr, llm_provider, llm_api_key, llm_model.

Parte 5 — Risoluzione dei problemi

- Un video lungo non si trascrive: può superare MAX_MEDIA_MINUTES — alza il limite o usa DIOS.
- Un video YouTube fallisce: potrebbe non avere sottotitoli, o YouTube blocca l'IP del server — incolla i tuoi cookie di YouTube nelle Impostazioni, o imposta YT_PROXY/YT_COOKIES.
- Errore 413 al caricamento: alza MAX_UPLOAD_MB e il limite di body del reverse proxy.
- Un PDF è vuoto: era scansionato senza OCR per il tuo ruolo — usa ANGEL/DIOS o spunta «Forza OCR».
- Password DIOS dimenticata: se non impostata, ne viene stampata una casuale nei log all'avvio.

Escriba — di Diego Parrás · CeMIACE · SEUBES · FCE-UBA · Licenza MIT