

Escriba

O tradutor universal para o idioma da IA

Manual completo — usuários e administradores

Desenvolvido por Diego Parrás · CeMIACE · SEUBES · FCE-UBA

github.com/diegoparras/escriba

Parte 1 — Para usuários

O que é o Escriba?

O Escriba converte quase qualquer arquivo em Markdown limpo — texto com formatação, pronto para copiar, salvar ou enviar a uma IA. Lida com documentos, planilhas, slides, imagens, áudio, vídeo e YouTube.

Primeiros passos

- Digite a senha e entre (seu nível: HUMANO, ANGEL ou DIOS).
- Arraste arquivos para a área central, ou clique em «Selecionar arquivos».
- Clique em «Converter tudo». Aparece uma barra de progresso.
- Abra o resultado e use Pré-visualização / Markdown / Dividido. Copie ou baixe o .md (ou um .zip para vários arquivos).

Recursos principais

- Áudio e vídeo são transcritos localmente com Whisper; escolha o idioma nas opções avançadas.
- Cole um link do YouTube para obter a transcrição.
- O texto das imagens é processado por OCR automaticamente; PDFs digitalizados são detectados, processados e endireitados na hora.
- A IA é opcional (OpenAI, Gemini, OpenRouter) e o padrão é «Sem IA». Os modelos são listados automaticamente.
- Anonimização de PII para LLMs: motor local (NER + layout de faturas + detectores validados + regras próprias) com cinco modos de saída — tipado, anônimo, pseudonimização reversível (token → ao LLM → re-hidratar), mascaramento parcial (••••-3456) e hash estável (mesmo dado → mesmo pseudônimo entre documentos).
- Censura visual: baixe seu PDF ou imagem digitalizada com os dados tachados na página — redação real: o texto e os pixels abaixo são removidos do arquivo. Os metadados do documento (título, autor, palavras-chave) também são apagados, para que nada vazze pelas Propriedades do arquivo.
- Fila: converta tudo ou apenas os arquivos selecionados.
- Tema claro/escuro e interface disponível em 7 idiomas.
- Exporte além do Markdown: um menu unificado converte o resultado em Word (.docx), ODT, EPUB, HTML, LaTeX, reStructuredText ou XML estruturado (DocBook, JATS, TEI, OPML), via Pandoc — sem IA.
- Painel de preparação para LLM em cada conversão: contagem de tokens, tokens e custo economizados pela anonimização, uma estimativa de custo ao vivo por modelo (preços da OpenRouter), encaixe na janela de contexto, fragmentação RAG em um clique e um detector de injeção de prompt — tudo local.
- Extração avançada de PDF (opcional): o motor OpenDataLoader reconstrói layouts complexos com melhor ordem de leitura e hierarquia de títulos, recorrendo automaticamente ao extrator padrão.
- Seleção de páginas (PDF): converta apenas as páginas que você precisa — um intervalo (5-67), páginas individuais (1, 6, 9) ou uma mistura (1, 2, 5-67), escolhidas por arquivo com um seletor simples que mostra a quantidade de páginas.

Parte 2 — Papéis e níveis de acesso

O login é obrigatório. Cada nível tem sua própria senha e limites, todos configuráveis por variáveis de ambiente.

Capacidade	HUMANO	ANGEL	DIOS
Enviar e converter arquivos	Sim	Sim	Sim
Converter de URL pública	Não	Sim	Sim
URL interna / caminho local	Não	Não	Sim
Áudio / vídeo / ZIP	Não	Sim	Sim
Transcrições do YouTube	Sim	Sim	Sim
OCR (forçado / automático)	Não	Sim	Sim
Usar chaves de IA do servidor	Não	Sim	Sim
Tamanho máx. de arquivo	25 MB	100 MB	ilimitado
Arquivos por lote	3	10	ilimitado
Limite de requisições (req/min)	15	60	ilimitado

Parte 3 — Para administradores

Arquitetura

O Escriba roda em um único contêiner Docker autossuficiente que inclui FastAPI + Markdown, ffmpeg, Tesseract + OCRmyPDF, faster-whisper e um Redis embutido. Executa como usuário não-root, com healthcheck e detecção automática de núcleos.

Implantação

Execute a imagem pronta (sem build):

```
docker run -d --name escriba -p 8000:8000 \
  -e SECRET_KEY="<long-random-key>" \
  -e GOD_PASSWORD="<your-password>" \
  ghcr.io/diegoparras/escriba:latest
```

Ou com Docker Compose:

```
git clone https://github.com/diegoparras/escriba.git
cd escriba
cp .env.example .env
docker compose up -d --build
```

EasyPanel/Portainer/Dokploy: crie um App a partir da imagem Docker ghcr.io/diegoparras/escriba:latest, adicione as variáveis de ambiente, aponte o domínio para a porta 8000 do contêiner com HTTPS e implante.

Variáveis de ambiente

Variável	Padrão	Descrição
SECRET_KEY	aleatória	Chave de assinatura das sessões. Defina em produção.
GOD/ANGEL/HUMAN_PASSWORD	—	Senha de cada nível de acesso.
HUMAN_OPEN	false	Permite o nível HUMANO sem login.
WEB_CONCURRENCY	auto	Workers paralelos (auto = núcleos da CPU).
MAX_UPLOAD_MB	100	Tamanho máximo de upload (exceto DIOS).
WHISPER_MODEL	base	Modelo de transcrição (tiny ... large-v3).
MAX_MEDIA_MINUTES	120	Limite de duração áudio/vídeo (0 = ilimitado).
OPENAI/OPENROUTER/GOOGLE_API_KEY	—	Chaves de IA do servidor (fallback).
API_TOKEN / API_TOKEN_ROLE	— / angel	Token para automação e seu papel.
EMBEDDED_REDIS	true	Redis embutido para o limite compartilhado.
ENABLE_DOCS	false	Expor Swagger em /api/docs.

Chaves de IA do servidor

- Se definidas, os usuários não precisam colar a própria. Apenas DIOS e ANGEL as usam.
- O custo é seu e compartilhado. Deixe-as vazias para cada um usar a própria.
- Uma chave do usuário sempre tem prioridade sobre a do servidor.

Transcrição (Whisper)

- Defina o modelo com WHISPER_MODEL (maior = mais preciso, mais lento).
- Roda na CPU. MAX_MEDIA_MINUTES limita a duração (DIOS sem limite).

Token de API (automação)

Para n8n ou scripts, defina API_TOKEN e envie como cabeçalho:

```
curl -H "X-API-Key: YOUR_TOKEN" \
  -F "file=@document.pdf" \
  https://your-domain/api/convert
```

Segurança

- Autenticação obrigatória; três papéis com permissões distintas.
- Anti-SSRF (IPs internos/redirecionamentos bloqueados); caminhos locais só para DIOS.
- Sanitização XSS (DOMPurify) e cabeçalhos de segurança (CSP).
- Contêiner não-root com no-new-privileges; OCR/Whisper sem shell.
- Limite de requisições por papel; a API key nunca é armazenada no servidor.

Privacidade

Os arquivos enviados são processados em um temporário e apagados assim que a conversão termina (sucesso ou erro). Não há banco de dados nem pasta de uploads; o resultado é enviado apenas ao seu navegador.

Parte 4 — Referência da API

Endpoint	Método	Descrição
/api/login	POST	Login; define um cookie de sessão.
/api/me	GET	Papel atual e capacidades.
/api/convert	POST	Converte um arquivo ou URL em Markdown.
/api/models	POST	Lista os modelos do provedor.
/api/stats	GET	Estatísticas do servidor (por papel).
/api/export	POST	Converte Markdown em docx, odt, epub, html, latex, rst ou XML (DocBook/JATS/TEI/OPML).
/api/compact	POST	Markdown sem espaços extras para economizar tokens.
/api/chunk	POST	Fragmentos RAG limitados por tokens (.jsonl).
/api/model_prices	GET	Preços de modelos e janelas de contexto ao vivo (OpenRouter, em cache).

POST /api/convert (multipart/form-data): file ou url, mais os opcionais lang, ocr, llm_provider, llm_api_key, llm_model.

Parte 5 — Solução de problemas

- Um vídeo longo não transcreve: pode exceder MAX_MEDIA_MINUTES — aumente o limite ou use DIOS.
- Um vídeo do YouTube falha: pode não ter legendas, ou o YouTube bloqueia o IP do servidor — cole seus cookies do YouTube nas Configurações, ou defina YT_PROXY/YT_COOKIES.
- Erro 413 no upload: aumente MAX_UPLOAD_MB e o limite de body do proxy reverso.
- Um PDF saiu vazio: estava digitalizado sem OCR para seu papel — use ANGEL/DIOS ou marque «Forçar OCR».
- Esqueceu a senha do DIOS: se não a definiu, uma aleatória aparece nos logs ao iniciar.

Escriba — por Diego Parrás · CeMIACE · SEUBES · FCE-UBA · Licença MIT