

Escriba

为 LLM 准备干净、匿名的 Markdown

完整手册 —— 用户与管理员

由 Diego Parrás 开发 · CeMIACE · SEUBES · FCE-UBA

github.com/diegoparras/escriba

第 1 部分 —— 面向用户

什么是 Escriba?

Escriba 能将几乎任何文件转换为干净的 Markdown —— 带格式的纯文本，便于复制、保存或交给 AI。支持文档、表格、幻灯片、图片、音频、视频和 YouTube。

快速上手

- 输入密码并登录（你的级别：HUMANO、ANGEL 或 DIOS）。
- 将文件拖到中间区域，或点击「选择文件」。
- 点击「全部转换」，会出现进度条。
- 打开结果，使用 预览 / Markdown / 分屏。复制或下载 .md（多个文件可下载 .zip）。

主要功能

- 音频和视频使用 Whisper 在本地转写；在高级选项中选择语言。
- 粘贴 YouTube 链接即可获取其转写。
- 图片中的文字会自动 OCR；扫描版 PDF 会被检测、即时处理并自动纠正旋转。
- AI 为可选（OpenAI、Gemini、OpenRouter），默认「不使用 AI」。模型会自动列出。
- 为 LLM 的 PII 匿名化：本地引擎（NER + 发票版面 + 校验检测器 + 自定义规则），五种输出模式：类型化、匿名、可逆假名化（占位符 → 发给 LLM → 还原）、部分掩码（••••-3456）和稳定哈希（相同数据 → 跨文档相同假名）。
- 可视化遮蔽：下载 PII 在页面上被涂黑的 PDF 或扫描图片 — 真正的涂黑：文字与底层像素都从文件中删除。
- 队列：可转换全部或仅所选文件。
- 浅色/深色主题，界面提供 7 种语言。

第 2 部分 —— 角色与访问级别

必须登录。每个级别都有独立的密码与限额，均可通过环境变量配置。

能力	HUMANO	ANGEL	DIOS
上传并转换文件	是	是	是
从公开网址转换	否	是	是
内网网址 / 本地路径	否	否	是
音频 / 视频 / ZIP	否	是	是
YouTube 转写	是	是	是
OCR (强制 / 自动)	否	是	是
使用服务器 AI 密钥	否	是	是
单文件最大大小	25 MB	100 MB	无限制
每批文件数	3	10	无限制
限流 (次/分钟)	15	60	无限制

第 3 部分 —— 面向管理员

架构

Escriba 在单一、自包含的 Docker 容器中运行，内置 FastAPI + MarkItDown、ffmpeg、Tesseract + OCRmyPDF、faster-whisper 和内嵌 Redis。以非 root 用户运行，带健康检查并自动检测 CPU 核心。

部署

运行预构建镜像（无需构建）：

```
docker run -d --name escriba -p 8000:8000 \
  -e SECRET_KEY="<long-random-key>" \
  -e GOD_PASSWORD="<your-password>" \
  ghcr.io/diegoparras/escriba:latest
```

或使用 Docker Compose：

```
git clone https://github.com/diegoparras/escriba.git
cd escriba
cp .env.example .env
docker compose up -d --build
```

EasyPanel/Portainer/Dokploy：用 Docker 镜像 ghcr.io/diegoparras/escriba:latest 创建一个 App，添加环境变量，将域名指向容器端口 8000 并启用 HTTPS，然后部署。

环境变量

变量	默认值	说明
SECRET_KEY	随机	会话签名密钥。生产环境请设置。
GOD/ANGEL/HUMAN_PASSWORD	—	各访问级别的密码。
HUMAN_OPEN	false	允许 HUMANO 级别免登录。
WEB_CONCURRENCY	auto	并行 worker (auto = CPU 核心数) 。
MAX_UPLOAD_MB	100	上传大小上限 (DIOS 除外) 。
WHISPER_MODEL	base	转写模型 (tiny ... large-v3) 。
MAX_MEDIA_MINUTES	120	音视频时长上限 (0 = 无限制) 。
OPENAI/OPENROUTER/GOOGLE_API_KEY	—	服务器端 AI 密钥 (回退) 。
API_TOKEN / API_TOKEN_ROLE	— / angel	自动化令牌及其角色。
EMBEDDED_REDIS	true	内嵌 Redis, 用于共享限流。
ENABLE_DOCS	false	在 /api/docs 暴露 Swagger。

服务器端 AI 密钥

- 设置后，用户无需粘贴自己的密钥。仅 DIOS 与 ANGEL 使用。
- 费用由你承担且为共享。留空则各用户自带密钥。
- 用户提供的密钥始终优先于服务器密钥。

转写 (Whisper)

- 用 WHISPER_MODEL 设置模型（越大越准但越慢）。
- 在 CPU 上运行。MAX_MEDIA_MINUTES 限制时长（DIOS 无上限）。

API 令牌 (自动化)

用于 n8n 或脚本：设置 API_TOKEN 并作为请求头发送：

```
curl -H "X-API-Key: YOUR_TOKEN" \
  -F "file=@document.pdf" \
  https://your-domain/api/convert
```

安全

- 需要身份验证；三种角色权限各异。
- 防 SSRF（拦截内网 IP/重定向）；本地路径仅限 DIOS。
- XSS 净化（DOMPurify）与安全响应头（CSP）。
- 非 root 容器并启用 no-new-privileges；OCR/Whisper 不经 shell。
- 按角色限流；API 密钥绝不存储在服务器。

隐私

上传的文件在临时文件中处理，转换结束（成功或失败）后立即删除。没有数据库，也没有上传目录；结果仅发送到你的浏览器。

第 4 部分 —— API 参考

端点	方法	说明
/api/login	POST	登录；设置会话 Cookie。
/api/me	GET	当前角色与能力。
/api/convert	POST	将文件或网址转换为 Markdown。
/api/models	POST	列出提供商的模型。
/api/stats	GET	服务器统计（按角色）。

POST /api/convert (multipart/form-data) : file 或 url, 以及可选的 lang、ocr、llm_provider、llm_api_key、llm_model。

第 5 部分 —— 常见问题

- 长视频无法转写：可能超过 MAX_MEDIA_MINUTES —— 调高上限或使用 DIOS。
- YouTube 视频失败：可能没有字幕，或 YouTube 屏蔽了服务器 IP —— 在「设置」中粘贴你的 YouTube Cookies，或设置 YT_PROXY/YT_COOKIES。
- 上传出现 413：调高 MAX_UPLOAD_MB 以及反向代理的 body 限制。
- PDF 结果为空：它是扫描版且你的角色无 OCR —— 使用 ANGEL/DIOS 或勾选「强制 OCR」。
- 忘记 DIOS 密码：若未设置，启动时会在容器日志中打印一个随机密码。

Escriba —— 由 Diego Parrás 开发 · CeMIACE · SEUBES · FCE-UBA · MIT 许可证